Números Fraccionarios

Organización del computador - FIUBA

2.do cuatrimestre de 2023
Última modificación: Mon Sep 4 15:50:28 2023 -0300

Créditos

Para armar las presentaciones del curso utilizamos:

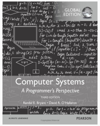

R. E. Bryant and D. R. O'Hallaron, *Computer systems: a programmer's perspective*, Third edition, Global edition. Boston Columbus Hoboken Indianapolis New York San Francisco Cape Town: Pearson, 2015.

D. A. Patterson and J. L. Hennessy, *Computer organization and design: the hardware/software interface*, RISC-V edition. Cambridge, Massachusetts: Morgan Kaufmann Publishers, an imprint of Elsevier, 2017.

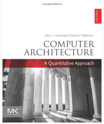

J. L. Hennessy and D. A. Patterson, *Computer architecture: a quantitative approach*. 2017.

El contenido de los slides está basado en las presentaciones de Patricio Moreno y de Organización del Computador I - FCEN.

Tabla de contenidos

Para qué?...

Luego de la clase de hoy deberíamos poder contestar las siguientes preguntas:

- ¿Cuándo conviene utilizar *floats* sobre *ints*?
- ¿Cuándo conviene utilizar *ints* sobre *floats*?
- ¿Que unidades o módulos del procesador intervienen en cada caso?

Además, deberíamos poder:

- Entender y explicar la representación en punto fijo.
- Entender y explicar la representación en punto flotante.

Floating Point Puzzles

- Argumentar si es cierta, o explicar por qué es falsa cada una de las siguientes expresiones de C:

```c
int x = ...;
float f = ...;
double d = ...;
```

Asumir que no son `NaN` `f` ni `d`

1. `x == (int) (float) x;`
2. `x == (int) (double) x;`
3. `f == (float) (double) f;`
4. `d == (double) (float) d;`
5. `f == -(-f);`
6. `2/3 == 2/3.0;`
7. `d < 0 ⇒ ((d*2) < 0)`
8. `d > f ⇒ -f > -d`
9. `d * d >= 0`
10. `(d + f) - d == f`

Tabla de contenidos

Números fraccionarios en binario

¿Qué es $\texttt{11000000.11011010}_2$?

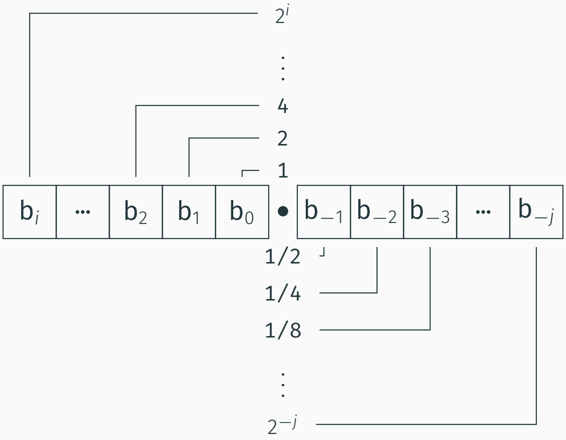

Ejemplos

•Representación	Valor
101.11_2	5 3/4
10.111_2	2 7/8
1.0111_2	1 7/16

- **Observaciones**
  - Desplazamiento a derecha: división por 2 (`unsigned`)
  - Desplazamiento a izquierda: multiplicación por 2
  - Números de la forma: $\texttt{0.111111...}_2$ son casi 1.0
    - $1/2 + 1/4 + 1/8 + \cdots + 1/2^i + \cdots \to 1{,}0$
    - $1 - \varepsilon$
  - Números periódicos: `0.0011[0011]...`

Números representables

- Limitación #1
  - Representa exactamente números de la forma $x/2^k$ únicamente
    - Otros números racionales tienen representaciones periódicas

•Valor	Representación
1/3	$\texttt{0.0101010101[01]...}_2$
1/5	$\texttt{0.001100110011[0011]...}_2$
1/10	$\texttt{0.0001100110011[0011]...}_2$

- Limitación #2
  - Sólo una posición del punto binario entre los w bits
    - Rango limitado (¿valores grandes? ¿valores chicos?)

Tabla de contenidos

Representación en punto fijo (decimal)

- Representación escalada:
  - `16.162` se puede representar como `16162` con un escalado de 1/1000.
  - `16162` se puede representar como `16.162` con un escalado de 1000.
- Cantidad de decimales fijos
- Se eliminan los decimales
- La aritmética de punto fijo es la de los enteros

Ejemplo: punto fijo en base 10

Definiciones

Sea $x = 4681$, $y = 3511$, $k = 1/10$ el escalado (1 decimal). Entonces:

x representa el número 468,1, e y representa el número 351,1.

suma/resta

$s = x + y = \frac{4681}{10} + \frac{3511}{10} = \frac{8192}{10} = 819{,}2.$

$r = x - y = \frac{4681}{10} - \frac{3511}{10} = \frac{1170}{10} = 117{,}0.$

multiplicación

$m = x \cdot y = \frac{4681}{10} \cdot \frac{3511}{10} = \frac{16434991}{100} = 164349{,}91$. Hay que ajustar a 1 decimal (dividir por 10).

$m = \frac{1643499{,}1}{10}.$

división

$d = x/y = \frac{4681}{10} / \frac{3511}{10} = 1{,}3332\ldots$. Hay que ajustar a 1 decimal (multiplicar por 10). $d = \frac{13{,}332}{10}.$

Representación en punto fijo (binario)

- Análoga a la versión decimal
- Cambia la base ($b = 2$) y el escalado ($k = 2^i$)
- Puede ser signada o no signada
- Aritmética de enteros
- Agregamos el tamaño de la palabra de la máquina (w)
- Separamos los w bits en la parte entera y la parte fraccional
  - Qd: d bits en la parte fraccionaria, ¿w?
  - Qi, d: i bits en la parte entera, d en la fraccionaria, $w = i + d + 1$
  - `fx`i, w: i bits en la parte entera, $d = w - i - 1$
  - `fixed`<w,d>: d bits en la parte fraccionaria, $i = w - d - 1$

Ejemplo: `Q5,2`

```
f = 010010.10

 ?  16   8   4   2   1     0.5  0.25
 0   1   0   0   1   0  .   1     0
--------------------------------------
                          suma  18.5
```

Ejemplo: punto fijo en base 2

Representación: `Q6.2`

```
a = 01001010 = 18.50 (01001010 / 4)
b = 01010111 = 21.75 (01010111 / 4)
```

suma (ej. unsigned)

```
    01001010 (74)
 +  01010111 (87)
 ----------------
    10100001 (161)
 ----------------
   101000.01 (40.25)
```

resta (ej. con signo)

```
    01001010 (74)
 -  01010111 (87)
 ----------------
    11110011 (-13)
 ----------------
   111100.11 (-3.25)
```

multiplicación

```
            01001010 (74)
 *          01010111 (87)
 ------------------------
    0001100100100110 (6438)
 ------------------------
   000110010010.0110 (402.375)
```

división

```
    01001010 (74)
 /  01010111 (87)
 ----------------
    00000000 (0)
 ----------------
   000000.00 (0.00)
```

Multiplicación en punto fijo: detalles

Representación: `Q6.2`

```
a = 01001010 = 18.50 (01001010 / 4)
b = 01010111 = 21.75 (01010111 / 4)
```

multiplicación

```
          01001010 (74)
 *        01010111 (87)
----------------------
  0001100100100110 (6438)
----------------------
 000110010010.0110 (402.375)
```

Puede hacer overflow

- Si se puede: promover enteros
- Ajustar resultado (+1)
- Desplazar (escalar correctamente)
- Truncar (o redondear)

- Requiere el doble de bits
- Tiene el doble de precisión

multiplicación

```
   0000000001001010 (74)
 * 0000000001010111 (87)
----------------------
   0001100100100110 (6438)
----------------------
   0001100100100111 (6438+1)
----------------------
   0000011001001001 (6438+1 >> 2)
----------------------
  00000110010010.01 (402.375)
```

Multiplicación en punto fijo: detalles

Representación: `Q6.2`

```
a = 01001010 = 18.50 (01001010 / 4)
b = 01010111 = 21.75 (01010111 / 4)
```

- Si se puede: promover enteros
- Ajustar resultado (+1)
- Desplazar (escalar correctamente)
- Truncar (o redondear)

Multiplicación en punto fijo: detalles

Representación: Q6.2

```
a = 01001010 = 18.50 (01001010 / 4)
b = 01010111 = 21.75 (01010111 / 4)
```

multiplicación

```
    0000000001001010   (74)
  * 0000000001010111   (87)
-------------------------------
    0001100100100110   (6438)
-------------------------------
    0001100100100111   (6438+1)
-------------------------------
    0000011001001001   (6438+1 >> 2)
-------------------------------
           010010.01   (18.25)
```

- Si se puede: promover enteros
- Ajustar resultado (+1)
- Desplazar (escalar correctamente)
- Truncar (o redondear)

Multiplicación en punto fijo: detalles

Representación: Q6.2

```
a = 01001010 = 18.50 (01001010 / 4)
b = 01010111 = 21.75 (01010111 / 4)
```

- Si se puede: promover enteros
- Ajustar resultado (+1)
- Desplazar (escalar correctamente)
- Truncar (o redondear)

multiplicación

```
    0000000001001010   (74)
  * 0000000001010111   (87)
  ------------------------------
    0001100100100110   (6438)
  ------------------------------
    0001100100100111   (6438+1)
  ------------------------------
    0000011001001001   (6438+1 >> 2)
  ------------------------------
           010010.01   (18.25)
```

promoción a `uint16_t`

Multiplicación en punto fijo: detalles

Representación: Q6.2

```
a = 01001010 = 18.50 (01001010 / 4)
b = 01010111 = 21.75 (01010111 / 4)
```

- Si se puede: promover enteros
- Ajustar resultado (+1)
- Desplazar (escalar correctamente)
- Truncar (o redondear)

multiplicación

```
    0000000001001010   (74)        promoción a uint16_t
  * 0000000001010111   (87)        promoción a uint16_t
  -------------------------------
    0001100100100110   (6438)
  -------------------------------
    0001100100100111   (6438+1)
  -------------------------------
    0000011001001001   (6438+1 >> 2)
  -------------------------------
           010010.01   (18.25)
```

Multiplicación en punto fijo: detalles

Representación: Q6.2

```
a = 01001010 = 18.50 (01001010 / 4)
b = 01010111 = 21.75 (01010111 / 4)
```

- Si se puede: promover enteros
- Ajustar resultado (+1)
- Desplazar (escalar correctamente)
- Truncar (o redondear)

multiplicación

```
    0000000001001010   (74)            promoción a uint16_t
  * 0000000001010111   (87)            promoción a uint16_t
  ----------------------------------
    0001100100100110   (6438)          resultado en uint16_t
  ----------------------------------
    0001100100100111   (6438+1)
  ----------------------------------
    0000011001001001   (6438+1 >> 2)
  ----------------------------------
           010010.01   (18.25)
```

Multiplicación en punto fijo: detalles

Representación: Q6.2

```
a = 01001010 = 18.50 (01001010 / 4)
b = 01010111 = 21.75 (01010111 / 4)
```

- Si se puede: promover enteros
- Ajustar resultado (+1)
- Desplazar (escalar correctamente)
- Truncar (o redondear)

multiplicación

```
    0000000001001010   (74)              promoción a uint16_t
  * 0000000001010111   (87)              promoción a uint16_t
  ----------------------------------
    0001100100100110   (6438)            resultado en uint16_t
  ----------------------------------
    0001100100100111   (6438+1)          ajustado + 1
  ----------------------------------
    0000011001001001   (6438+1 >> 2)
  ----------------------------------
           010010.01   (18.25)
```

Multiplicación en punto fijo: detalles

Representación: Q6.2

```
a = 01001010 = 18.50 (01001010 / 4)
b = 01010111 = 21.75 (01010111 / 4)
```

- Si se puede: promover enteros
- Ajustar resultado (+1)
- Desplazar (escalar correctamente)
- Truncar (o redondear)

multiplicación

```
    0000000001001010   (74)             promoción a uint16_t
  * 0000000001010111   (87)             promoción a uint16_t
  -----------------------------------
    0001100100100110   (6438)           resultado en uint16_t
  -----------------------------------
    0001100100100111   (6438+1)         ajustado + 1
  -----------------------------------
    0000011001001001   (6438+1 >> 2)    corregir escalado y truncar
  -----------------------------------
           010010.01   (18.25)
```

Tabla de contenidos

Punto Flotante (IEEE[1])

Estándar IEEE 754

- Establecido en 1985
  - IEEE 754-1985 - IEEE Standard for Binary Floating-Point Arithmetic
  - IEEE 754-2008 - IEEE Standard for Floating-Point Arithmetic
  - última revisión: IEEE 754-2019 - IEEE Standard for Floating-Point Arithmetic
- Soporte general
  - Hardware
  - Software
- Desarrollado *mirando* las necesidades numéricas
  - Formas estándar de redondeo, *overflow*, *underflow*
  - Difícil obtener realizaciones veloces en hardware
    - Análisis numérico *vs* diseño de hardware

[1] IEEE: Instituto de Ingenieros Eléctricos y Electrónicos

Representación

Expresión numérica

$$f = (-1)^{s}\ M\ 2^{E}$$

- s: bit de signo
- M: significando (normalmente un valor en el intervalo [1.0, 2.0))
- E: exponente, pesa el valor por una potencia de 2

Codificación (almacenamiento)

- El msb `s` es el bit de signo s
- `exp` codifica E, pero no es E
- `frac` codifica M, pero no es M

s	exp	frac

Precisión

Precisión simple: 32 bits

s	exp	frac
1	8 bits	23 bits

Precisión doble: 64 bits

s	exp	frac
1	11 bits	52 bits

Precisión extendida: 80 bits (Intel)

s	exp	frac
1	15 bits	64 bits

Valores: normalizados

$V = (-1)^s M\, 2^E$

- Cuando `exp` $\neq$ `000…0` y `exp` $\neq$ `111…1`
- Exponente codificado por exceso: E = `Exp - bias`
  - `Exp`: valor `unsigned` del campo `exp`
  - `bias`: $2^{k-1} - 1$, donde k es el número de bits del campo `exp`
    - Simple: 127 (Exp: 1, …, 254; E: -126, …, 127)
    - Doble: 1023 (Exp: 1, …, 2046; E: -1022, …, 1023)
- Significando codificado con parte entera implícitamente 1: M = $\texttt{1.sss…s}_2$
  - `sss…s`: bits del campo `frac`
  - Mínimo cuando `frac = 00…0` (M = 1.0)
  - Máximo cuando `frac = 11…1` (M = 2.0 - ε)

Ejemplo de codificación normalizada

$$v = (-1)^s \, M \, 2^E$$
$$E = Exp - bias$$

Valor: `float F = 49374.0;`

- $49374{,}0_{10} = 1100000011011110_2$
  $= 1.100000011011110_2 \times 2^{15}$

Significando

$M = 1.100000011011110_2$

$\texttt{frac} = 10000001101111000000000_2$

Exponente

$E = 15$

$\texttt{bias} = 127$

$\texttt{exp} = 142 = 10001110$

Resultado

s	exp	frac
0	100 0111 0	100 0000 1101 1110 0000 0000

Ejemplo de codificación normalizada

Representación en punto flotante

0	100 0111 0	100 0000 1101 1110 0000 0000
s	exp	frac

Hexa:	4	7	4	0	D	E	0	0
Binario:	0100	0111	0100	0000	1101	1110	0000	0000
142:	100	0111	0					
49374:			1100	0000	1101	1110		

Valores: de(s)normalizados

$$v = (-1)^s M 2^E$$
$$E = 1 - bias$$

- Cuando `exp = 000…0`
- Exponente: E = `1 - bias` (en vez de $0 - bias$)
  - Simple: -126
  - Doble: -1022
- Significando codificado con parte entera implícitamente 0: M = $\texttt{0.sss…s}_2$
  - `sss…s`: bits del campo `frac`
- Casos
  - `exp = 000…0, frac = 000…0`
    - Representa el valor cero (0)
    - Distintos valores para `+0` y `-0`
  - `exp = 000…0, frac` $\neq$ `000…0`
    - Valores más cercanos a 0.0
    - Equiespaciados

Valores especiales

- **Condición:** `exp = 111…1`
- Caso: `exp = 111…1, frac = 000…0`
  - Representa el valor ∞ (infinito)
  - Operaciones que dan *overflow*
  - Hay positivo y negativo
  - Ej.: $1{,}0/0{,}0 = -1{,}0/-0{,}0 = +\infty$, $1{,}0/-0{,}0 = -\infty$
- Caso: `exp = 111…1`, `frac` $\neq$ `000…0`
  - `NaN`: Not-A-Number
  - Representa casos donde no se puede determinar un valor numérico
  - Ej.: $sqrt(-1)$, $\infty - \infty$, $\infty \times 0$

Visualización

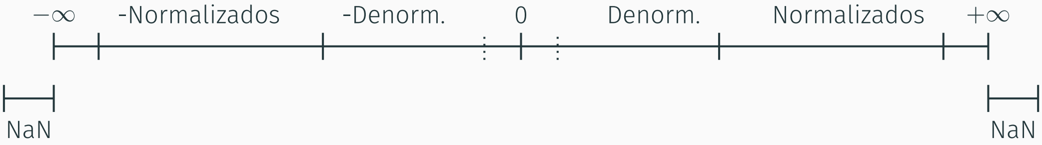

Tabla de contenidos

Ejemplo con un float pequeño

s	exp	frac
1	4 bits	3 bits

Representación en punto flotante de 8 bits

- el bit de signo es el msb
- el exponente es de 4 bits: `bias = 7`
- la parte fraccionaria: 3 bits

Misma idea que el formato IEEE

- normalizados, denormalizados
- representación del 0, NaN, infinito

Rango Dinámico (positivos)

	s	exp	frac	E	Valor	
Números denormalizados	0	0000	000	-6	0	cero
	0	0000	001	-6	$1/8\ 2^{-6} = 1/512$	denormalizado menor
	0	0000	010	-6	$2/8\ 2^{-6} = 2/512$	
	$\vdots$					
	0	0000	110	-6	$6/8\ 2^{-6} = 6/512$	
	0	0000	111	-6	$7/8\ 2^{-6} = 7/512$	denormalizado mayor
Números Normalizados	0	0001	000	-6	$8/8\ 2^{-6} = 8/512$	normalizado menor
	0	0001	001	-6	$9/8\ 2^{-6} = 9/512$	
	$\vdots$					
	0	0110	110	-1	$14/8\ 2^{-1} = 14/16$	
	0	0110	111	-1	$15/8\ 2^{-1} = 15/16$	más cercano a 1 (menor)
	0	0111	000	0	$8/8\ 2^{0} = 1$	1
	0	0111	001	0	$9/8\ 2^{0} = 9/8$	más cercano a 1 (mayor)
	0	0111	010	0	$10/8\ 2^{0} = 10/8$	
	$\vdots$					
	0	1110	110	7	$14/8\ 2^{7} = 224$	
	0	1110	111	7	$15/8\ 2^{7} = 240$	normalizado mayor
	0	1111	000	--	∞	infinito

Distribución de valores: mini float

float tipo IEEE de 6 bits

- fracción de 2 bits
- exponente de 3 bits
- `bias` = $2^{3-1} - 1 = 3$

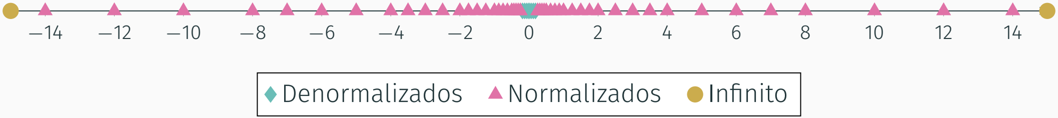

Distribución de valores (zoom): mini float

float tipo IEEE de 6 bits

- fracción de 2 bits
- exponente de 3 bits
- `bias` = $2^{3-1} - 1 = 3$

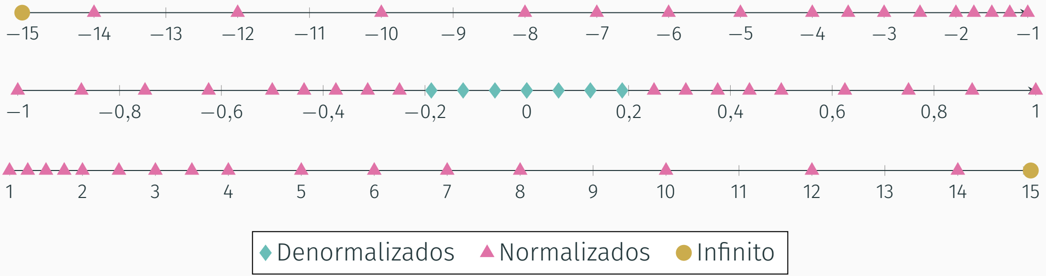

Propiedades de la codificación según el IEEE

El cero de punto flotante (FP) es el mismo que con los enteros
·Todos los bits en 0

Casi sirve la comparación de enteros

- Comparar primero los bits de signo
- Tener en cuenta que FP tiene 2 ceros (-0 y $+0$)
- `NaN` es problemático
  - Es mayor que cualquier otro número
  - ¿Qué debe dar la comparación?
- Caso contrario, está bien
  - Denormalizados *vs* Normalizados
  - Normalizados *vs* Infinito

Rangos (positivos)

$\{\texttt{simple}, \texttt{doble}\}$

Descripción	`exp`	`frac`	Valor numérico
Cero	`00…00`	`00…00`	$0{,}0$
Denormalizado menor	`00…00`	`00…01`	$2^{-\{23,52\}} \times 2^{-\{126,1022\}}$
simple $\approx 1{,}4 \times 10^{-45}$			
doble $\approx 4{,}9 \times 10^{-324}$			
Denormalizado mayor	`00…00`	`11…11`	$(1{,}0 - \varepsilon) \times 2^{-\{126,1022\}}$
simple $\approx 1{,}18 \times 10^{-38}$			
doble $\approx 2{,}2 \times 10^{-308}$			
Normalizado menor	`00…01`	`00…00`	$1{,}0 \times 2^{-\{126,1022\}}$
Uno (1)	`01…11`	`00…00`	$1{,}0$
Normalizado mayor	`11…10`	`11…11`	$(2{,}0 - \varepsilon) \times 2^{\{127,1023\}}$

Tabla de contenidos

Operaciones con punto flotante

- $u +_f v = Round(u + v)$
- $u \times_f v = Round(u \times v)$

Idea básica

- Primero obtener el resultado exacto
- Ajustarlo a la precisión disponible
  - Puede haber overflow si el exponente es grande
  - Redondear para que entre en `frac`

Redondeo

- Hay 4 modos de redondeo
  - Hacia 0, $-\infty$, $+\infty$, el más cercano (*nearest*)

Ejemplos

Hacia	\$1,40	\$1,60	\$1,50	\$2,50	–\$1,50
0	\$1,00	\$1,00	\$1,00	\$2,00	–\$1,00
abajo ($-\infty$)	\$1,00	\$1,00	\$1,00	\$2,00	–\$2,00
arriba ($+\infty$)	\$2,00	\$2,00	\$2,00	\$3,00	–\$1,00
el más cercano	\$1,00	\$2,00	\$2,00	\$2,00	–\$2,00

El redondeo por omisión es al (par) más cercano, llamado **Round-to-Even**

Round-to-Even

- Es el modo por omisión
  - No es simple configurar otro modo
  - Todos los demás están estadísticamente sesgados

Ejemplo: redoneando a 2 decimales

- Cuando se está justo en el medio entre 2 valores
  - Redondear para que el dígito menos significativo sea par
- Ejemplo

7.8949999	7.89	(Por debajo de la mitad)
7.8950001	7.90	(Por arriba de la mitad)
7.8950000	7.90	(Justo en la mitad–redondear hacia arriba)
7.8850000	7.88	(Justo en la mitad–redondear hacia abajo)

Redondeo en binario

- Números fraccionarios
  - "Par" cuando el bit menos significativo es 0
  - "En la mitad" cuando los bits a la derecha de la posición de redondeo son: $100\ldots0_2$

Ejemplo

- Redondear al 1/4 más cercano (2 bits después del punto)

Valor	Binario_2	Redondeado_2	Acción	Final
2 3/32	10.00011_2	10.00_2	(<1/2–abajo)	2
2 3/16	10.00110_2	10.01_2	(>1/2–arriba)	2 1/4
2 7/8	10.11100_2	11.00_2	(1/2–arriba)	3
2 5/8	10.10100_2	10.10_2	(1/2–abajo)	2 1/2

Multiplicación

Operación: $(-1)^{s_1}\ M_1\ 2^{E_1} \times (-1)^{s_2}\ M_2\ 2^{E_2}$

Resultado Exacto: $(-1)^{s}\ M\ 2^{E}$

- signo **s** s_1 ^ s_2
- significando **M** $M_1 \times M_2$
- exponente **E** $E_1 + E_2$

Ajuste

- Si $M \geq 2$, desplazar `M` a la derecha, incrementar `E`
- Si `E` fuera de rango, *overflow*
- Redondear `M` para concuerde con la precisión de `frac`

Implementación

- Lo más difícil es multiplicar los significandos

Suma

Operación: $(-1)^{S_1}\, M_1\, 2^{E_1} + (-1)^{S_2}\, M_2\, 2^{E_2}$

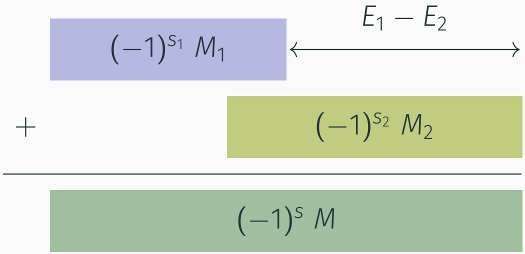

Resultado Exacto: $(-1)^{S}\, M\, 2^{E}$

- signo **s**, significando **M**:
  - Resultado de alinear y sumar
- exponente **E**: E_1

Ajuste

- Si $M \geq 2$, desplazar **M** a la derecha, incrementar **E**
- Si $M < 1$, desplazar **M** a la izquierda, decrementar **E**
- Si **E** fuera de rango, *overflow*
- Redondear **M** para concuerde con la precisión de `frac`

Propiedades matemáticas de la suma

- Comparando con un grupo abeliano
  - ¿Cerrado bajo la suma? Sí
  - ¿Es conmutativa? Sí
  - ¿Es asociativa? No
    - Puede ocurrir un *overflow*; es inexacto (redondea)
    - Ej.: `(3.14+1e10) - 1e10 = 0.0` , `3.14 + (1e10-1e10) = 3.14`
  - ¿Es 0 la identidad aditiva? Sí
  - ¿Todo elemento tiene un inverso? Casi
    - Excepto los infinitos y NaNs
- Monotonicidad
  - $a \geq b \;\&\; c \geq 0 \quad \Rightarrow \quad a + c \geq b + c$? Casi
    - Salvo por infinitos y/o NaNs

Propiedades matemáticas de la multiplicación

- Comparando con un anillo conmutativo
  - ¿Cerrado bajo la multiplicación? Sí
  - ¿Es conmutativa la multiplicación? Sí
  - ¿Es asociativa la multiplicación? No
    - Puede ocurrir un *overflow*; es inexacto (redondea)
    - Ej.: `(1e20*1e20) * 1e-20 = inf` , `1e20 * (1e20*1e-20) = 1e20`
  - ¿Es 1 la identidad multiplicativa? Sí
  - ¿Es distributiva sobre la suma? No
    - Puede ocurrir un *overflow*; es inexacto (redondea)
    - Ej.: `1e20 * (1e20-1e20) = 0.0` , `1e20*1e20 - 1e20*1e20) = NaN`
- Monotonicidad
  - $a \geq b \;\&\; c \geq 0 \quad \Rightarrow \quad a * c \geq b * c$? Casi
    - Salvo por infinitos y/o NaNs

Tabla de contenidos

Punto Flotante en C

- C garantiza 2 tipos
  - `float`: precisión simple
  - `double`: precisión doble
- Conversiones/*casting*
  - *casting* entre `int`, `float`, y `double` cambia la representación binaria
  - `double`/`float` $\longrightarrow$ `int`
    - Trunca la parte fraccionaria
    - Como redondear hacia 0
    - No está definido cuando el valor está fuera de rango o es NaN: generalmente asigna TMin.
  - `int` $\longrightarrow$ `double`
    - Conversión exacta, en tanto el `int` tenga menos de 53 bits
  - `int` $\longrightarrow$ `float`
    - En general va a redondear (salvo enteros de 16 bits o menos)

Floating Point Puzzles

·Argumentar si es cierta, o explicar por qué es falsa cada una de las siguientes expresiones de C:

```c
int x = ...;
float f = ...;
double d = ...;
```

Asumir que no son `NaN` `f` ni `d`

```
1. x == (int) (float) x;
2. x == (int) (double) x;
3. f == (float) (double) f;
4. d == (double) (float) d;
5. f == -(-f);
6. 2/3 == 2/3.0;
7. d < 0 ⇒ ((d*2) < 0)
8. d > f ⇒ -f > -d
9. d * d >= 0
10. (d + f) - d == f
```

Licencia del estilo de beamer

Obtén el código de este estilo y la presentación demo en

`github.com/pamoreno/mtheme`

El estilo *en sí* está licenciado bajo la Creative Commons Attribution-ShareAlike 4.0 International License. El estilo es una modificación del creado por Matthias Vogelgesang, disponible en

`github.com/matze/mtheme`